

Seja (X_1, \dots, X_n) uma amostra aleatória (a.a) de $X \sim f_\theta, \theta \in \Theta$

a **Função Densidade de Probabilidade** conjunta de (X_1, X_2, \dots, X_n) é $\forall \theta \in \Theta$,

no caso discreto:

$$P_\theta(X_1 = k_1, X_2 = k_2, \dots, X_n = k_n) \stackrel{\text{ind}}{=} \prod_{i=1}^n P_\theta(X_i = k_i) \stackrel{\text{id}}{=} \prod_{i=1}^n P_\theta(X = k_i) \stackrel{\text{def}}{=} \prod_{i=1}^n f_\theta(k_i)$$

no caso contínuo:

$$f_\theta^{(x)}(k_1, k_2, \dots, k_n) \stackrel{\text{i.i.d}}{=} \prod_{i=1}^n f_\theta(k_i)$$

Exemplo

Seja (X_1, X_2, X_3) uma a.a de $X \sim \text{Ber}(\theta), \theta \in (0, 1)$

1. Especifique o espaço paramétrico
2. Calcule a função de probabilidade da amostra
3. Encontre as seguintes **Quantidade de Interesse** em função de θ
 1. $g(\theta) = E_\theta(X)$
 2. $g(\theta) = P_\theta(X = 0)$
 3. $g(\theta) = \text{CV}_\theta(X)$

Resolução

4. $\Theta = (0, 1)$
5. Duas resoluções possíveis
 1. Dando valores à amostra

$$\begin{aligned} &P(X_1 = k_1, X_2 = k_2, X_3 = k_3) = \\ &\prod_{i=1}^3 P_\theta(X = k_i) = \\ &(0, 0, 0) \quad (1 - \theta)^3 \backslash \\ &(0, 0, 1) \quad (1 - \theta)^2 \theta \backslash \\ &(0, 1, 0) \quad (1 - \theta)^2 \theta \backslash \\ &(1, 0, 0) \quad (1 - \theta)^2 \theta \backslash \\ &(0, 1, 1) \quad (1 - \theta) \theta^2 \backslash \\ &(1, 0, 1) \quad (1 - \theta) \theta^2 \backslash \\ &(1, 1, 0) \quad (1 - \theta) \theta^2 \backslash \\ &(1, 1, 1) \quad \theta^3 \end{aligned}$$

2. Enunciando a função Observe que, se $k \in \{0, 1\}$,

```

\begin{aligned}
&\mathbb{P}(\theta(X=k)=\theta^k(1-\theta)^{1-k}\cdot\mathbb{1}_{\{0,1\}}(k))\rightarrow\\
&\mathbb{P}(\theta(X_1=k,X_2=k_2,X_3=k_3))\stackrel{\text{i.i.d}}{=}\prod_{i=1}^3\{\theta^{k_i}(1-\theta)^{1-k_i}\cdot\mathbb{1}_{\{0,1\}}(k_i)\}\\
&= \theta^{\sum_{i=1}^3k_i}(1-\theta)^{3-\sum_{i=1}^3k_i}\prod_{i=1}^3\mathbb{1}_{\{0,1\}}(k_i)
\end{aligned}

```

6. Em função de θ :

1. $g(\theta) = E_{\theta}(X) = \theta$
2. $g(\theta) = P_{\theta}(X = 0) = 1 - \theta$
3. $g(\theta) = CV_{\theta}(X) = \frac{\sqrt{\theta(1-\theta)}}{\theta}$

Outro exemplo

Seja (X_1, \dots, X_n) uma a.a de $X \sim \text{Ber}(\theta), \theta \in (0, 1)$, encontre a f.p conjunta da amostra.

$$\begin{aligned}
 P_{\theta}(X_1 = k_1, \dots, X_n = k_n) &\stackrel{\text{iid}}{=} \prod_{i=1}^n P_{\theta}(X = k_i) = \prod_{i=1}^n \{\theta^{k_i} (1 - \theta)^{1-k_i} \mathbb{1}_{\{0,1\}}(k_i)\} \\
 &\Rightarrow P_{\theta}(X_1 = k_1, \dots, X_n = k_n) = \theta^{\sum_{i=1}^n k_i} \cdot \theta^{n - \sum_{i=1}^n k_i} \cdot \mathbb{1}_{\{0,1\}}(k_i)
 \end{aligned}$$

Mais um exemplo

Seja (X_1, \dots, X_n) uma a.a de $X \sim \text{Pois}(\theta), \theta \in (0, \infty)$, encontre a f.p conjunta da amostra.

Como esse vetor é uma a.a. (ou seja, variáveis aleatórias independentes e identicamente distribuídas), temos que

$$P_{\theta}(X_1 = k_1, \dots, X_n = k_n) \stackrel{\text{iid}}{=} \prod_{i=1}^n P_{\theta}(X = k_i) = \prod_{i=1}^n \{e^{-\theta} \cdot \frac{\theta^{k_i}}{k_i!}\}$$

Sempre que $k_i \in \{0, 1, \dots\}, \forall i = 1, \dots, n$

$$\Rightarrow P_{\theta}(\dots) = e^{-n\theta} \cdot \frac{\theta^{\sum_{i=1}^n k_i}}{\prod_{i=1}^n (k_i)!}$$

Um exemplo para contínua,

Seja (X_1, \dots, X_n) uma a.a de $X \sim \text{Exp}(\theta), \theta \in (0, \infty)$, encontre a f.d.p

conjunta da amostra.

$$F_{\theta}^{(*)}(k_1, \dots, k_n) = \prod_{i=1}^n f_{\theta}(k_i) = \prod_{i=1}^n \{\theta e^{-\theta k_i} \cdot \mathbb{1}_{(0, \infty)}(k_i)\} \Rightarrow f_{\theta}^{(*)}(\dots) = \theta^n \cdot e^{-\theta \sum_{i=1}^n k_i} \cdot \prod_{i=1}^n \mathbb{1}_{(0, \infty)}(k_i)$$

Mais um,

Seja (X_1, \dots, X_n) uma a.a. (i.i.d) de $X \sim N(\mu, \sigma^2)$ em que

$\theta = (\mu, \sigma^2) \in \Theta = \mathbb{R} \times \mathbb{R}_+$. Considere $\tilde{x} = (x_1, \dots, x_n)$ a amostra observada.

$$L_{\tilde{x}} = \prod_{i=1}^n f_{\theta}(x_i) = \prod_{i=1}^n \left\{ \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(x_i - \mu)^2\right\} \right\} = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

Função de Verossimilhança

Obs: quando analisamos a distribuição conjunta da amostra em função de θ nos valores da amostra observada, temos a Função de Verossimilhança

$$L_{\tilde{x}}(\theta) = P_{\theta}(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

em que $\tilde{x} = (x_1, x_2, \dots, x_n)$ é a amostra observada.

Obs: A função de verossimilhança, no caso discreto, é a probabilidade de observar a amostra observada.

Exemplo

Considere (X_1, X_2, X_3, X_4) a.a de $X \sim \text{Ber}(\theta), \theta \in \{0.1, 0.5, 0.9\}$. Note que o espaço paramétrico é $\Theta = \{0.1, 0.5, 0.9\}$. Considere, ainda, que a amostra observada foi $(0, 1, 1, 1)$. Encontre a função de verossimilhança.

$$L_{\tilde{x}}(\theta) = P_{\theta}(X_1 = x_1, X_2 = x_2, X_3 = x_3, X_4 = x_4) = \theta^{\sum_{i=1}^4 x_i} (1 - \theta)^{4 - \sum_{i=1}^4 x_i} \cdot \prod_{i=1}^4 \mathbb{1}_{\{0,1\}}(x_i) = \theta^3 (1 - \theta)$$

Estimação via máxima verossimilhança (EMV)

O valor numérico $\hat{\theta}_n$ que maximiza a função de verossimilhança, ou seja, $L_{\tilde{x}}(\hat{\theta}_n) \geq L_{\tilde{x}}(\theta) \forall \theta \in \Theta$ é dito ser uma **estimativa** de máxima verossimilhança (MV) para θ . Observe que $\hat{\theta}_n$ depende da **amostra observada** e portanto: $\hat{\theta}_n = \hat{\theta}(x_1, x_2, \dots, x_n)$.

O **estimador** de máxima verossimilhança é obtido substituindo (x_1, \dots, x_n) por (X_1, \dots, X_n) , ou seja, $\hat{\theta}_{(X_1, \dots, X_n)}$ é o Estimador de

Máxima Verossimilhança (EMV)

Exemplo:

Seja (X_1, \dots, X_n) a.a de $X \sim f_\theta, \theta \in \{\frac{1}{3}, \frac{1}{2}\}$ em que f_θ é uma função de probabilidade que satisfaz:

$X = x :$	0	1	2
$f_\theta(x) :$	θ	θ^2	$1 - \theta - \theta^2$

Considere que a amostra observada é $\tilde{x} = (0, 0, 1)$.

a-) Encontre a estimativa da máxima verossimilhança

Sabemos que

$$f_\theta(x) = \theta^{\mathbb{1}_{\{0\}}(x)} \cdot (\theta^2)^{\mathbb{1}_{\{1\}}(x)} \cdot (1 - \theta - \theta^2)^{\mathbb{1}_{\{2\}}(x)} \forall \theta \in \Theta$$

portanto,

$$L_{\tilde{x}}(\theta) = \prod_{i=1}^n f_\theta(x_i) = \theta^{\sum_{i=1}^n \mathbb{1}_{\{0\}}(x_i)} \cdot (\theta^2)^{\sum_{i=1}^n \mathbb{1}_{\{1\}}(x_i)} \cdot (1 - \theta - \theta^2)^{\sum_{i=1}^n \mathbb{1}_{\{2\}}(x_i)} \forall \theta \in \Theta$$

Para $\tilde{x} = (0, 0, 1)$,

$$L_{\tilde{x}}(\theta) = \theta^2 \cdot \theta^2 \cdot (1 - \theta - \theta^2)^0 = \theta^4 \forall \theta \in \Theta$$

Substituindo $\forall \theta \in \Theta$:

$$\theta = \frac{1}{2} \Rightarrow L_{\tilde{x}}\left(\frac{1}{2}\right) = \frac{1}{16} \quad \theta = \frac{1}{3} \Rightarrow L_{\tilde{x}}\left(\frac{1}{3}\right) = \frac{1}{81}$$

Portanto, $\hat{\theta}_n = \frac{1}{2}$ é a estimativa de máxima verossimilhança.

Invariância dos EMVs

Teorema.

Se $\hat{\theta}_{(X_1, \dots, X_n)}$ for EMV para θ , então $g(\hat{\theta}_{(X_1, \dots, X_n)})$ é o EMV para $g(\theta)$, ou seja, $g(\hat{\theta}_n)$ é a estimativa de máxima verossimilhança para $g(\theta)$

Mais um exemplo.

Seja (X_1, \dots, X_n) a.a. de $X \sim N(\mu, \sigma^2)$ em que $\theta = (\mu, \sigma^2) \in \Theta = \mathbb{R} \times \mathbb{R}^+$

Assuma que $\tilde{x} = (x_1, \dots, x_n)$ é a amostra observada.

Lembrando que estaremos chamando $\theta = (\mu, \sigma^2)$, mas estes são parâmetros genéricos. Poderíamos, por exemplo, chamá-los de $\theta = (\theta_1, \theta_2)$, o que pode facilitar a visualizar algumas derivadas.

a-) Encontre as estimativas de máxima verossimilhança para $\theta = (\mu, \sigma^2)$:

A Função de Verossimilhança é:

$$\begin{aligned} L_{\tilde{x}}(\theta) &= \prod_{i=1}^n f_{\theta}(x_i) = \prod_{i=1}^n \left\{ \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp \left\{ \frac{-1}{2} \cdot \frac{(x_i - \mu)^2}{\sigma^2} \right\} \right\} \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \cdot \exp \left\{ \frac{-1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \end{aligned}$$

Podemos derivar para encontrar o máximo da FMV. Para isso, derivaremos e igualamos a zero primeiro em relação a μ e então a σ^2 (podemos aplicar o logaritmo para facilitar as operações.)

$$\frac{\partial \ln(L_{\tilde{x}})}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\frac{\partial \ln(L_{\tilde{x}})}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0$$

\therefore

$$\begin{aligned} \text{Estimativas MV} &= \begin{cases} \mu = \bar{x} \\ -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases} \\ &\Leftrightarrow \begin{cases} \hat{\mu} = \bar{x} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases} \end{aligned}$$

Estes são os pontos que maximizam a Função de Máxima Verossimilhança. (Provados em cálculo), ou seja, são as estimativas de máxima verossimilhança para μ, σ^2 respectivamente, e $\hat{\mu}(X_1, \dots, X_n) = \bar{X}, \hat{\sigma}^2(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ são os estimadores de máxima verossimilhança.

Pela propriedade de invariância podemos encontrar o EMV para $g(\theta) = \frac{\sqrt{\text{Var}_{\theta}(\bar{X})}}{E_{\theta}(\bar{X})}$:

$$\widehat{g(\theta)} = \frac{\sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}}{\bar{X}}$$

Observação:

Seja (X_1, \dots, X_n) a.a. de $X \sim N(\mu, \sigma^2)$. Então,

1-) $\bar{X} \underset{\text{Exata!}}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right) \forall \mu, \sigma \in \mathbb{R} : \sigma^2 > 0 \text{ e } n \geq 1$

2-) $\sum_{i=1}^n \frac{(x_i - \bar{X})^2}{\sigma^2} \underset{\text{Exata!}}{\sim} \chi_{(n-1)}^2$ em que χ_k^2 representa a **Distribuição Qui-Quadrado** com k grau de liberdade, cuja função densidade de probabilidade é:

$$f(x) = \frac{1}{\Gamma(\frac{k}{2})2^{\frac{k}{2}}} \cdot x^{\frac{k}{2}-1} \cdot \exp\left\{\frac{-x}{2}\right\} \cdot \mathbb{1}_{(0,\infty)}(x)$$

Para qualquer outra distribuição, existe um resultado aproximado pelo

Teorema do Limite Central

Seja X_1, \dots, X_n a.a de $X \sim f_\theta, \theta \in \Theta : E_\theta(X^2) < \infty$, então:

$$\bar{X} \underset{\sim}{\overset{\text{Aproximadamente}}{N}} \left(E_\theta(X), \frac{\text{Var}_\theta X}{n} \right)$$

Formalmente, temos o enunciado do *Teorema do Limite Central*:

$$\frac{\sqrt{n}(\bar{X} - E_\theta(x))}{\sqrt{\text{Var}_\theta(X)}} \underset{n \rightarrow \infty}{\overset{\text{Distribuição}}{\rightarrow}} N \sim (0, 1) \forall \theta \in \Theta$$

Se $X \sim N(\mu, \sigma)$, então a distribuição é exata.

Ademais, seja g uma função contínua e diferenciável tal que $g'(\theta) \neq 0$. Então,

$$g(\bar{X}) \underset{\sim}{\overset{\text{Aproximadamente}}{N}} \left(g(E_\theta(X)), \frac{g'(E_\theta(X))^2 \text{Var}_\theta(X)}{n} \right)$$

Exemplo:

Seja (X_1, \dots, X_n) a.a de $X \sim \text{Ber}(\theta), \theta \in (0, 1)$. Já vimos que EMV p/θ é

$$\bar{\theta}(X_1, \dots, X_n) = \bar{X}$$

$$\text{Var}_{\theta(x)} p/g(\theta) = \text{Var}_{\theta(x)} = \theta(1 - \theta) \text{ é :}$$

$$\widehat{g(\theta)} = \bar{X}(1 - \bar{X}).$$

$$\bar{X} \underset{\sim}{\overset{\text{approx.}}{N}} \left(\theta, \frac{\theta(1 - \theta)}{n} \right)$$

$$\begin{aligned} \text{Agora, } g(\bar{X}) = \bar{X}(1 - \bar{X}) &\underset{\sim}{\overset{\text{approx.}}{N}} \left(\theta(1 - \theta), \frac{[g'(\theta)]^2 \theta(1 - \theta)}{n} \right) \\ &\Rightarrow N \left(\theta(1 - \theta), \frac{(1 - 2\theta)^2 \theta(1 - \theta)}{n} \right) \end{aligned}$$