

Em teoria de probabilidades, conhecemos a medida de probabilidade, logo, fazemos descrições probabilísticas.

$$(\Omega, \mathcal{A}, P) \xrightarrow{X} (\mathbb{R}, \mathcal{B}, P_X)$$

Na prática, contudo, não conhecemos a medida P .

Abordagem Clássica

Definimos então uma família de medidas de probabilidades que possivelmente descrevem o comportamento aleatório dos dados.

O *Modelo Estatístico* é definido pela trinca

$$(\Omega, \mathcal{A}, \mathcal{P})$$

em que Ω é o espaço amostral (evento certo), \mathcal{A} é a [Probabilidade > Sigma álgebra](#), uma família de subconjuntos ou eventos em Ω e \mathcal{P} é uma família de medidas de probabilidade que possivelmente descrevem o comportamento aleatório dos dados ou eventos sobre investigação.

Modelo Estatístico Paramétrico

Se $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$, em que $\Theta \subseteq \mathbb{R}^P$ e $p \in \mathbb{N}$, então dizemos que $(\Omega, \mathcal{A}, \mathcal{P})$ é um modelo estatístico ***Paramétrico*.

Caso não exista $\Theta \subseteq \mathbb{R}^P$ fixo, então dizemos que o modelo é não-paramétrico.

Obs: Θ é o espaço paramétrico e θ é o vetor de parâmetros. θ Não* é variável aleatória, apenas indexa as medidas de probabilidade.

Exemplos

Exemplo de Bernoulli

Considere um [Ensaio de Bernoulli](#)

$$\Omega = \{S, F\}, \mathcal{A} = 2^\Omega$$

Temos algum conhecimento prévio que sugere que as probabilidades de sucesso podem ser 0.1, 0.5, 0.9

Nesse caso,

$$\mathcal{P} = \{P_1, P_2, P_3\}$$

em que

$$\begin{cases} P_1(\{S\}) = 0.1; P_1(\{F\}) = 0.9; P_1(\Omega) = 1 \\ P_2(\{S\}) = 0.5; P_2(\{F\}) = 0.5; P_2(\Omega) = 1 \\ P_3(\{S\}) = 0.9; P_3(\{F\}) = 0.1; P_3(\Omega) = 1 \end{cases}$$

Observe que

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}$$

em que $\Theta = \{1, 2, 3\} \subseteq \mathbb{R}$

Portanto, $(\Omega, \mathcal{A}, \mathcal{P})$ é um modelo paramétrico.

Exemplo de Exponencial

Seja $X: \Omega \rightarrow \mathbb{R}$ tal que

$$X(\omega) = \begin{cases} 1, \omega = S \\ 0, c. c. \end{cases}$$

$$E_\theta(X) = \sum_{x=0}^1 x P_\theta(X = x)$$

$$\begin{cases} \theta = 1 \Rightarrow E_1(X) = 0.1 \\ \theta = 2 \Rightarrow E_2(X) = 0.5 \\ \theta = 3 \Rightarrow E_3(X) = 0.9 \end{cases}$$

Seja $\Omega = (0, \infty)$ e \mathcal{A} uma sigma-álgebra de Ω ([Sigma-Álgebra de Borel](#))

Ω representa o tempo até a ocorrência de um evento (uma reclamação, por exemplo)

Temos conhecimento prévio de que as funções densidade de probabilidade que possivelmente descrevem esse evento são:

$$f_1(\omega) = \begin{cases} e^{-1\omega}, \omega > 0 \\ 0, c. c. \end{cases}$$

$$f_2(\omega) = \begin{cases} 2e^{-2\omega}, \omega > 0 \\ 0, c. c. \end{cases}$$

$$f_3(\omega) = \begin{cases} \frac{1}{2}e^{-\frac{1}{2}\omega}, \omega > 0 \\ 0, c. c. \end{cases}$$

$$f_4(\omega) = \begin{cases} \frac{1}{10}e^{-\frac{1}{10}\omega}, \omega > 0 \\ 0, c. c. \end{cases}$$

e P_S ,

$$P_1(A) = \int_A f_1(\omega) d\omega$$

$$P_2(A) = \int_A f_2(\omega) d\omega$$

$$P_3(A) = \int_A f_3(\omega) d\omega$$

$$P_4(A) = \int_A f_4(\omega) d\omega$$

Dessa forma,

$$P_\theta = \int_A f_\theta(\omega) d\omega, \omega \in \Omega$$

e $\Omega = \{1, 2, 3, 4\}$

Seja $X: \Omega \rightarrow \mathbb{R}$ tal que

$$X(\omega) = \omega$$

Note que

$$E_\theta(X) = \int_{-\infty}^{\infty} x f_\theta(x) dx, \theta \in \{1, 2, 3, 4\}$$

$$E_\theta(X) = \begin{cases} 1, & \theta = 1 \\ \frac{1}{2}, & \theta = 2 \\ 2, & \theta = 3 \\ 10, & \theta = 4 \end{cases}$$

Principais Modelos Estatísticos

Modelo Estatístico de Bernoulli

Dizemos que X é uma variável aleatória com modelo de Bernoulli se, e somente se,

$$P_\theta(X = x) = \begin{cases} \theta^x \cdot (1 - \theta)^{1-x}, & x \in \{0, 1\} \\ 0, & x \notin \{0, 1\} \end{cases}$$

em que $\theta \in \Theta$ e $\Theta = (0, 1) \subseteq \mathbb{R}$

O parâmetro é a probabilidade de sucesso

$$\begin{cases} E_\theta(X) = \theta \\ \text{Var}_\theta(X) = \theta(1 - \theta) \\ P_\theta(X = 1) = \theta, P_\theta(X = 0) = 1 - \theta \end{cases}$$

Modelo Estatístico Binomial

Dizemos que X é uma variável aleatória com modelo binomial se, e somente se,

$$P_{\theta}(X = x) = \begin{cases} \binom{n}{x} \cdot \theta^x \cdot (1 - \theta)^{n-x}, & x \in \{0, 1, \dots, n\} \\ 0, & x \notin \{0, 1, \dots, n\} \end{cases}$$

em que n é conhecido e fixado previamente, θ é a probabilidade de sucesso (parâmetro do modelo) e $\Theta = (0, 1)$ é o espaço paramétrico

$$\begin{cases} E_{\theta}(X) = n\theta \\ \text{Var}_{\theta}(X) = n\theta(1 - \theta) \\ P_{\theta}(X = 0) = (1 - \theta)^n, \dots, P_{\theta}(X = n) = \theta^n \end{cases}$$

Modelo Estatístico Geométrico

Dizemos que X é uma variável aleatória com modelo estatístico geométrico se, e somente se,

$$P_{\theta}(X = x) = \begin{cases} \theta(1 - \theta)^{x-1}, & x \in \{1, \dots\} \\ 0, & x \notin \{1, \dots\} \end{cases}$$

em que θ é o parâmetro do modelo (probabilidade de sucesso) e $\Theta = (0, 1)$ é o espaço paramétrico

$$\begin{cases} E_{\theta}(X) = \frac{1}{\theta} \\ \text{Var}_{\theta}(X) = \frac{1 - \theta}{\theta^2} \end{cases}$$

Modelo de Poisson

Dizemos que X é uma variável aleatória com modelo estatístico Poisson, se, e somente se,

$$P_{\theta}(X = x) = \begin{cases} e^{-\theta} \cdot \frac{\theta^x}{x!}, & x \in \{0, 1, \dots\} \\ 0, & x \notin \{0, 1, \dots\} \end{cases}$$

em que θ é a taxa média de ocorrência do evento (parâmetro do modelo) e $\Theta = (0, \infty)$, o espaço paramétrico.

$$\begin{cases} E_{\theta}(X) = \theta \\ \text{Var}_{\theta}(X) = \theta \end{cases}$$

Modelo Multinomial

Dizemos que X é um **Vetor Aleatório** com modelo estatístico Multinomial se, e somente se a função de probabilidade é

$$P_{\theta}(X_1 = x_1, \dots, X_k = x_k) = \begin{cases} \frac{n!}{x_1!x_2!\dots x_k!} \cdot \theta_1^{x_1} \cdot \dots \cdot \theta_k^{x_k} & x_1 + \dots + x_k = n \\ 0, c. c. & \end{cases}$$

em que $\theta_1 + \dots + \theta_k = 1$ e $0 \leq \theta_i \leq 1, \forall i = 1, 2, \dots, k,$

$\Theta = \{(\theta_1, \dots, \theta_k) \in \mathbb{R}^k : 0 \leq \theta_i \leq 1, i = 1, \dots, k, \theta_1 + \dots + \theta_k = 1\}$

$$\begin{cases} E_{\theta}(X_i) = n\theta_i \\ \text{Var}_{\theta}(X_i) = n\theta_i(1 - \theta_i) \\ \text{Cov}(X_i X_j) = -n\theta_i\theta_j \end{cases}$$

Esse modelo tem aplicação em modelos de linguagem como o ChatGPT. (k como tamanho do vocabulário, $n=1$, θ_1 = probabilidade de escolher o primeiro elemento do vocabulário e assim por diante.)

Modelo Uniforme contínuo

Dizemos que X é uma **variável aleatória contínua** com modelo estatístico Uniforme em $(\theta_1, \theta_2), \theta_2 > \theta_1$, se, e somente se, a sua **Função Densidade de Probabilidade**

$$f_{\theta}(x) = \begin{cases} \frac{1}{\theta_2 - \theta_1}, x \in (\theta_1, \theta_2) \\ 0, c. c. \end{cases}$$

em que $\theta = (\theta_1, \theta_2)$ vetor, $\Theta = \{\theta \in \mathbb{R}^2 : \theta_2 > \theta_1\}$

$$\begin{cases} E_{\theta}(X) = \frac{b+a}{2} \\ \text{Var}_{\theta}(X) = \frac{(b-a)^2}{12} \end{cases}$$

$X \sim U(\theta_1, \theta_2), \theta = (\theta_1, \theta_2)$ Vetor de Parâmetros

Modelo Exponencial

Dizemos que X é uma **variável aleatória contínua** com modelo estatístico Exponencial se, e somente se, a sua **Função Densidade de Probabilidade** é dada por

$$f_{\theta}(x) = \begin{cases} \theta e^{-\theta x}, x > 0 \\ 0, c. c. \end{cases}$$

em que $\theta > 0, \Theta = \{\theta \in \mathbb{R} : \theta > 0\}$

$$\begin{cases} E_{\theta}(X) = \frac{1}{\theta} \\ \text{Var}_{\theta}(X) = \frac{1}{\theta^2} \end{cases}$$

$X \sim \text{Exp}(\theta), \theta > 0$

Modelo Normal

Dizemos que X é uma **variável aleatória contínua** com modelo estatístico normal com média μ e variância σ^2 se, e somente se, a sua **Função Densidade de Probabilidade** é dada por

$$f_{\theta}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, x \in \mathbb{R}$$

em que $\theta = (\mu, \sigma^2) \in \Theta = \{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}^+\}$

$$\begin{cases} E_{\theta}(X) = \mu \\ \text{Var}_{\theta}(X) = \sigma^2 \end{cases}$$

$X \sim N(\mu, \sigma^2), \theta = (\mu, \sigma^2)$ Vetor de Parâmetros