

Sejam  $X, Y$  duas variáveis de interesse representando duas sub-populações. Estamos interessados em verificar se a média populacional de  $X$  é menor, maior ou igual à de  $Y$ . Sendo assim, precisamos considerar os casos em que  $X$  é independente de  $Y$  e o caso em que não são independentes (pareados).

## Dados independentes e dependentes

Um pesquisador propôs um novo método de investimento para aumentar o rendimento mensal. Selecionou 20 investidores aleatoriamente de um universo de investidores cadastrados. Em um primeiro momento, o pesquisador deixou os investidores investirem do jeito que sabem e ao final verificou a renda obtida.

$X$  é o rendimento dos investidores sem ter o conhecimento do método.

Então, o pesquisador ensinou seu método aos investidores, onde  $Y$  passou a ser o rendimento dos investidores após a aplicação do método ensinado.

Claramente,  $X, Y$  são dependentes.

O mesmo pesquisador testará o mesmo método de forma diferente. Para testar o seu método, o pesquisador selecionou 20 indivíduos com características similares do universo de investidores, dos quais

1. 10 foram designados aleatoriamente a não receber o método  $X$ :  
rendimento de um indivíduo que não recebeu o método
  2. 10 foram designados aleatoriamente a receberem o método  $Y$ :  
rendimento de um indivíduo que recebeu o método
- Nesse caso, as variáveis  $X, Y$  são independentes.

Em ambas abordagens, temos as mesmas hipóteses de interesse:

$$1. \begin{cases} H_0 : \mu_X \geq \mu_Y \\ H_1 : \mu_X < \mu_Y \end{cases} \quad 2. \begin{cases} H_0 : \mu_X \leq \mu_Y \\ H_1 : \mu_X > \mu_Y \end{cases} \quad 3. \begin{cases} H_0 : \mu_X = \mu_Y \\ H_1 : \mu_X \neq \mu_Y \end{cases}$$

Podemos definir  $\mu_D = \mu_X - \mu_Y$  e reescrever as hipóteses

$$1. \begin{cases} H_0 : \mu_D \geq 0 \\ H_1 : \mu_D < 0 \end{cases} \quad 2. \begin{cases} H_0 : \mu_D \leq 0 \\ H_1 : \mu_D > 0 \end{cases} \quad 3. \begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$

Para os próximos exemplos, assumiremos normalidade para  $X, Y$

## Caso pareado (variáveis dependentes)

No caso em que  $X, Y$  são dependentes, as amostras são  $(X_n)$  a.a de  $X$  e  $(Y_n)$  a.a de  $Y$  tais que  $X_i, Y_i$  são dependentes.

Para este caso, fazemos  $D_i = X_i - Y_i, i = 1, 2, \dots, n$ . Temos que  $(D_n)$  é uma amostra aleatória de

$$D = X - Y \sim N(\mu_D, \sigma_D^2) = N(\mu_X - \mu_Y, \sigma_X^2 + \sigma_Y^2 - 2\rho\sigma_X\sigma_Y)$$

Observe ainda que

$$\bar{D}_{\text{Par}} = \sum_{i=1}^n \frac{D_i}{n} \sim N\left(\mu_D, \frac{\sigma_D^2}{n}\right)$$

Note ainda que as variância e covariância de  $X, Y$  estão embutidas em  $\sigma_D^2$ .

Podemos usar

$$s_D^2(\underset{\sim}{D}) = \frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D}_{\text{Par}})^2$$

Para estimar  $\sigma_D^2$

Podemos construir as decisões como já vimos anteriormente em [testes sob normalidade com variância desconhecida](#).

## Exemplo

Foram coletados os rendimentos (em mil reais) antes e após a aplicação o método para 12 investidores. Queremos verificar se o método aumentou o rendimento médio. Chamaremos de  $X$  o rendimento anterior ao treinamento e  $Y$  o rendimento após. Isto é, queremos verificar se  $\mu_D = \mu_X - \mu_Y \leq 0$ . Portanto, nossa hipótese nula é de que o treinamento não tem efeito positivo no rendimento:

$$\begin{cases} H_0 : \mu_D \geq 0 \\ H_1 : \mu_D < 0 \end{cases}$$

Índice	Antes( $X$ )	Depois( $Y$ )	Dif( $D$ )	Dif <sup>2</sup> ( $D^2$ )
1	2.4	4.3	-1.9	3.61
2	2.8	3.4	-0.6	0.36
3	4.6	3.2	1.4	1.96
4	3.1	3.3	-0.2	0.04
5	3.1	3.3	-0.2	0,04
6	4.7	5.8	-1.1	1.21
7	3.5	3.8	-0.3	0.09
8	1.7	3.5	-1.8	3.24
9	2.3	3.2	-0.9	0.81
10	2.6	3.9	-1.3	1.69
11	4.2	3.6	0.6	0.36
12	3.4	4.3	-0.9	0.81
Média	3.2	3.8	-0.6	
$s^2$	0.87	0.55	0.9	

Temos que  $s^2(D) = 0.9$ . (Podemos calcular diretamente ou usando a coluna  $D^2$  e substituindo no somatório  $s_D^2 = \left( \frac{\sum_{i=1}^n d_i^2}{n} - \bar{d}^2 \right) \frac{n}{n-1}$  )

Rejeitamos  $H_0$  se  $\frac{\bar{d}_{\text{par}}}{\sqrt{\frac{s_D^2}{n}}} < -t_{\alpha, n-1}$  onde  $t_{\alpha, n-1}$  é tal que

$P(t_{n-1} < -t_{\alpha, n-1}) = \alpha$ , onde  $t_{n-1}$  é a distribuição T de Student com  $n - 1$  graus de liberdade.

Temos que  $\frac{\bar{d}_{\text{par}}}{\sqrt{\frac{s_D^2}{n}}} = -2.19$  e, a  $\alpha = 0.05$ ,  $-t_{0.05, 11} = -1.796$ .

Como  $-2.19 < -1.796$ , podemos dizer que há evidências de que o método aumenta o rendimento médio dos investidores a 5% de significância. Por outro lado, com  $\alpha = 0.01$ ,  $-t_{0.01, 11} = -2.718$  e, por  $-2.19 \geq -2.718$ , dizemos que não há evidências para rejeitar a hipótese de que o método não aumenta o rendimento (rejeitar a hipótese nula) a 1% de significância estatística.

## Caso de independência

Sejam  $X, Y$  variáveis aleatórias *independentes* tais que

$$\begin{cases} X \sim N(\mu_X, \sigma_X^2) \\ Y \sim (\mu_Y, \sigma_Y^2) \end{cases}$$

Considere  $(X_n)$  amostra aleatória de  $X$  e  $(Y_m)$ . Estamos interessados em testar as hipóteses:

$$1. \begin{cases} H_0 : \mu_X \geq \mu_Y \\ H_1 : \mu_X < \mu_Y \end{cases} \quad 2. \begin{cases} H_0 : \mu_X \leq \mu_Y \\ H_1 : \mu_X > \mu_Y \end{cases} \quad 3. \begin{cases} H_0 : \mu_X = \mu_Y \\ H_1 : \mu_X \neq \mu_Y \end{cases}$$

Podemos definir  $\mu_D = \mu_X - \mu_Y$  e obter a equivalência dessas hipóteses

$$1. \begin{cases} H_0 : \mu_D \geq 0 \\ H_1 : \mu_D < 0 \end{cases} \quad 2. \begin{cases} H_0 : \mu_D \leq 0 \\ H_1 : \mu_D > 0 \end{cases} \quad 3. \begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$

Considere

$$\bar{D}_{\text{NPar}} = \bar{X} - \bar{Y}$$

Como  $\bar{X} \sim N\left(\mu_X, \frac{\sigma_X^2}{n}\right), \bar{Y} \sim N\left(\mu_Y, \frac{\sigma_Y^2}{m}\right)$ , temos que  $\bar{D}_{\text{NPar}} \sim N\left(\mu_D, \frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}\right)$

## Ambas variâncias conhecidas

Podemos substituir o valor numérico das variâncias na distribuição de  $\bar{D}_{\text{NPar}}$ , obtendo uma distribuição normal com pontos de corte para as decisões:

1. Rejeita  $H_0$  se  $\bar{d}_{\text{NPar}} < -z_\alpha \underbrace{\sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{m}}}_{\text{Var}(\bar{D}_{\text{NPar}})}, \sigma^2 = \sigma_X^2 = \sigma_Y^2$
2. Rejeita  $H_0$  se  $\bar{d}_{\text{NPar}} > z_\alpha \sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{m}}$
3. Rejeita  $H_0$  se  $\bar{d}_{\text{NPar}} < -z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{m}}$  ou  $\bar{d}_{\text{NPar}} > z_\alpha \sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{m}}$

## Variâncias desconhecidas e iguais

Temos que  $\sigma_X^2 = \sigma_Y^2 = \sigma^2$  é conhecido.

### Estimando via t-Student

Através da distribuição t-Student com  $n + m - 2$  graus de liberdade, podemos estimar os pontos de corte. Temos nossas decisões:

1. Rejeita  $H_0$  se  $\bar{d}_{\text{NPar}} < -t_{n+m-2, \alpha} \sqrt{\frac{s_p^2}{n} + \frac{s_p^2}{m}}$
2. Rejeita  $H_0$  se  $\bar{d}_{\text{NPar}} > t_{n+m-2, \alpha} \sqrt{\frac{s_p^2}{n} + \frac{s_p^2}{m}}$
3. Rejeita  $H_0$  se  $\bar{d}_{\text{NPar}} < -t_{n+m-2, \frac{\alpha}{2}} \sqrt{\frac{s_p^2}{n} + \frac{s_p^2}{m}}$  ou  $\bar{d}_{\text{NPar}} > t_{n+m-2, \frac{\alpha}{2}} \sqrt{\frac{s_p^2}{n} + \frac{s_p^2}{m}}$

Onde  $s_p^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n+m-2}$ , com  $s_X^2, s_Y^2$  sendo os estimadores não enviesados para as variâncias de  $X$  e  $Y$ , respectivamente. (Ponderamos os estimadores com base no tamanho de sua amostra, assim favorecendo os estimadores mais precisos)

## Variâncias desconhecidas e diferentes (caso geral)

Temos que  $\sigma_X^2, \sigma_Y^2$  são desconhecidos e diferentes.

### Estimando via t-Student

usaremos a distribuição t-Student com  $n'$  graus de liberdade. Temos nossas decisões:

1. Rejeita  $H_0$  se  $\bar{d}_{NPar} < -t_{n',\alpha} \sqrt{\frac{s_p^2}{n} + \frac{s_p^2}{m}}$
2. Rejeita  $H_0$  se  $\bar{d}_{NPar} > t_{n',\alpha} \sqrt{\frac{s_p^2}{n} + \frac{s_p^2}{m}}$
3. Rejeita  $H_0$  se  $\bar{d}_{NPar} < -t_{n',\frac{\alpha}{2}} \sqrt{\frac{s_p^2}{n} + \frac{s_p^2}{m}}$  ou  $\bar{d}_{NPar} > t_{n',\frac{\alpha}{2}} \sqrt{\frac{s_p^2}{n} + \frac{s_p^2}{m}}$

Onde  $s_p^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n+m-2}$ .

### Encontrando $n'$

Na fórmula acima, temos os graus de liberdade da t-Student dado por

$$n' \approx \frac{\left(\frac{s_X^2}{n} + \frac{s_Y^2}{m}\right)^2}{\frac{\left(\frac{s_X^2}{n}\right)^2}{n-1} + \frac{\left(\frac{s_Y^2}{m}\right)^2}{m-1}}$$

Esse valor, caso não inteiro, deverá ser arredondado.

### Exemplo (Importante)

Queremos testar a resistência de dois tipos de viga de aço,  $A$  e  $B$ . Tomando-se  $n=15$  vigas do tipo  $A$  e  $m=20$  vigas do tipo  $B$ . de um teste  $f$ , conseguimos com 10% de significância que as variâncias não são iguais. Obtemos os valores da tabela:

Tipo	Média	Variância( $s^2$ )
$A$	70.5	81.6
$B$	84.3	210.8
$\bar{d}_{\text{NPar}}$	-13.8	--

Teste a hipótese

$$\begin{cases} H_0 : \mu_X = \mu_Y \\ H_1 : \mu_X \neq \mu_Y \end{cases}$$

Com significância  $\alpha = 0.05$  para os casos

### Caso 1. Variâncias conhecidas

Temos do produtor que  $\sigma_X^2 = 81, \sigma_Y^2 = 209$

$\bar{d}_{\text{NPar}} = 70.5 - 84.3 = -13.8$ . Logo,

$z_{\frac{\alpha}{2}} \sqrt{\frac{81}{15} + \frac{209}{20}} = 7.8$ . Como  $-13.8 < -7.8$ , concluímos que há evidências para rejeitarmos a hipótese nula de que as resistências médias das vigas  $A, B$  são iguais a  $\alpha = 5\%$  de significância estatística

### Caso 2. Variâncias desconhecidas e iguais.

Para  $\alpha = 0.05$ ,  $t_{33,0.025} = 2.03$ . Encontrando  $s_P^2 = 155.988$ . Finalmente,

$$t_{33,0.025} \sqrt{\frac{s_P^2}{n} + \frac{s_P^2}{m}} = 8.65.$$

Como  $-13.8 < -8.65$ , concluímos que há evidências para rejeitarmos a hipótese nula a  $\alpha = 5\%$  de significância estatística.

### Caso 3. Variâncias desconhecidas e diferentes

Primeiro calculamos  $n' = 32.08 \stackrel{\text{Arredonda}}{=} 32$ . Assim,  $t_{32,0.025} = 2.037$ .

Portanto,  $t_{32,0.025} \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}} = 8.14$ . Como  $-13.8 < -8.15$ , concluímos que há evidências para rejeitarmos a hipótese nula a  $\alpha = 5\%$  de significância estatística.